

AI工具使用报告

陈雪琪 152403119 经济统计学

1 AI使用场景

1.1 数据读取与初步理解板块

读取`ershoufang_list.csv`时出现中文乱码，我不清楚编码参数，借助AI获取`encoding="utf-8-sig"`解决乱码问题。同时让AI整合代码，一次性输出数据集行列数量、`df.info()`字段类型、数值描述统计、各分类字段唯一值，不用分段运行代码。数据集共11856条数据、18个字段，AI辅助整理文字，完成报告中区域、户型、面积、价格字段的初步理解描述。

1.2 数据质量检查板块

缺失值、重复值、文本脏数据、数值异常校验代码繁琐，容易遗漏检查项。我将数据集字段提供给AI，生成全套质检代码：统计26条价格缺失样本、3283条标题+小区+面积重复房源、批量检测文本首尾空格、筛查楼层与建造年份异常、校验面积与均价极端值、计算总价与均价×面积的价格误差。运行代码得到完整脏数据统计结果，依托输出数据撰写第四章数据质量检查说明文字。

1.3 数据清洗与类型转换板块

原始面积、总价、楼层均为带汉字文本，手动提取数字效率低。我让AI编写正则提取函数`extract_num`，从“103m²”“250万”中提取纯数字，生成`clean_area`、`clean_total`、`clean_avg`数值字段；针对“中层(共31层)”这类文本编写分类函数，统一归类为低层/中层/高层；生成过滤代码删除价格缺失、均价极端样本，清洗后有效数据从11856条缩减至10235条。AI同步梳理清洗步骤文字，解释每一步处理目的，完善报告第五章内容。

1.4 pandas数据分析板块

多维度分组聚合、透视表语法不熟练，依靠AI生成完整统计代码：按行政区分组统计房源量、平均面积、均价；按楼层分类对比均价；制作行政区×楼层均价透视表；拆分户型文本提取室数，统计不同室数房源总量与平均总价。运行代码得到完整统计表格，对照表格数据撰写第六章描述统计解读。

1.5 可视化绘图板块

作业要求绘制4张图表，我不会统一配置中文防止乱码，双轴图、箱线图等参数复杂。AI提供四段完整绘图代码，自带全局中文设置，分别绘制：行政区房源数量&均价双轴图、分区域分层单价箱线图、房源面积分布直方图、多维指标堆叠面积图，自带标题、坐标轴、图例、刻度旋转设置。我基于AI基础代码，结合福州12个行政区真实数据微调配色、坐标范围。

1.6 Notebook报告文字撰写

对照试卷评分标准，我将代码运行结果、图表截图发给AI，生成完整报告文本，包含摘要、各章节操作说明、四张图表解读、数据局限性、核心分析结论。初稿完成后，我对照本地数据集运行结果，修改模板化、不符合福州二手房市场的语句。

2 使用成效

1. **数据读取与质检：**自行编写全套校验代码至少需要1小时，AI一次性生成完整代码，10分钟完成全部质量筛查，精准定位26条价格缺失、3283条重复房源、11830条总价均价逻辑冲突数据。
2. **数据清洗转换：**正则提取文本、楼层分类属于实操难点，AI提供的函数适配本数据集文本格式，顺利完成文本转数值、新增分类字段，得到10235条有效样本，满足“数据清洗与类型转换”评分要求。
3. **统计分析：**多维度分组、交叉透视代码一键生成，直观得出鼓楼均价全市最高、晋安房源供给最多、三室户型为市场主流等规律，大幅减少手动聚合统计工作量。
4. **可视化成果：**四段绘图代码无语法报错，四张图表正常显示中文、图例与坐标轴，箱线图区分三层楼层、双轴图同时展示供给量与单价，达到可视化板块评分标准。
5. **报告完整度：**AI搭建完整报告框架，覆盖摘要、数据说明、质检、清洗、统计、可视化、结论、局限性全部模块，匹配试卷所有评分项，节省大量梳理写作逻辑的时间。
6. **学习提升：**通过AI代码逐行注释，弄懂正则文本提取、双轴绘图、透视表交叉分析逻辑，掌握二手房混杂文本脏数据处理方法，弥补课堂实操练习不足。

3 使用中暴露的问题

1. **AI代码适配性差，无法匹配数据集特有问题**

AI原始价格校验代码未添加总价与均价的误差判断逻辑，无法识别11830条逻辑矛盾房源；堆叠面积图未缩小均价数值，原始数值过大导致图表色块失衡，需要手动增加除以100的数值转换代码。
2. **可视化代码模板化，图表细节不符合本地数据**

AI默认配色单一，未区分鼓楼、晋安等重点行政区；箱线图缺少每组房源数量标注；X轴刻度未适配福州12个区县名称，需要手动修改图例、刻度、文字标注。
3. **AI生成分析结论脱离福州房产真实特征**

AI输出通用房产模板文字，无法自动提炼鼓楼学区溢价、中层房价高于高低层、80-110m²刚需户型为主等专属结论，大段表述通用性强，需要逐条替换修改。
4. **产生工具依赖，自主实操思考减少**

正则清洗、多轴绘图、透视表等难点代码直接复制AI成品，没有先自主尝试编写；代码报错第一时间询问AI，缺少独立调试排查过程，弱化独立处理数据问题的能力。

5. 文字审核不细致，初期直接照搬AI内容

初期未对照自己运行的统计表格、图表核对文字，AI部分描述与真实数据存在偏差，比如片区房源数量描述错误，后期返工修改耗费额外时间。

4 后续改进方案

1. **数据预处理：**简单缺失值删除、基础筛选代码独立编写；仅复杂正则、多条件异常判断参考AI。针对本次大量价格逻辑冲突数据，下次先自行构思误差判断条件，再对比AI代码查漏补缺。
2. **可视化绘图：**仅借用AI绘图基础框架，配色、坐标轴范围、数值缩放、行政区标签、数据标注全部手动调整，根据数据集指标自定义参数，不直接运行原始模板代码。
3. **报告文字撰写：**AI仅用于梳理写作框架，所有分析描述、核心结论对照本地分组表格、四张图表逐句修改，删除通用模板语句，补充福州二手房专属市场特征，贴合本次数据集。
4. **调整学习习惯：**后续数据分析作业先独立完整编写一套代码，无法解决报错再求助AI；让AI逐行注释代码理解原理，之后重新手写一遍，减少直接复制代码行为，锻炼独立处理脏数据、绘图、统计的实操能力。
5. **建立审核习惯：**AI生成的代码、文字全部运行、通读核对，确认样本数量、均价区间、区域分布和本地数据集一致，修正偏差内容后再写入Notebook。

5 总结

本次《数据分析与可视化》福州二手房期末作业，从CSV数据读取、数据质量检查、文本清洗转换、多维度分组统计、四张可视化图表绘制到完整报告撰写，全程使用AI作为辅助工具。AI大幅缩短代码编写、报错调试、报告框架梳理的时间，整套Notebook代码可完整运行无报错，报告覆盖试卷全部评分板块，同时借助AI吃透课堂不熟练的正则文本提取、多维透视、双轴绘图等实操技能。

但实操过程中也存在明显短板：AI输出代码通用性强，不能适配本数据集特有的价格逻辑冲突、大量重复上架房源等脏数据；图表、文字存在模板化问题，必须结合福州本地房源数据手动修改；同时自身产生工具依赖，独立写代码、排查问题的练习不足。

后续完成数据分析类作业，我会调整使用方式，坚持自主编写代码、独立分析数据为主，仅将AI作为答疑、纠错、拓展思路的辅助工具，使用后仔细核对、修改全部AI输出内容，在借助工具提升效率的同时，锻炼自身独立数据分析能力。